UNIDAD 5: ALGORITMOS DE MEMORIA EXTERNA

ORDENAMIENTO Y BÚSQUEDA

Gibran Fuentes Pineda Junio 2021

Ordenamiento por distribución para memoria externa (1)

- Se usan S-1 elementos $e_1, \dots e_{S-1}$ para dividir problema en subarreglos S (cubetas)
- El *i*-ésimo subarreglo consiste en todos los elementos con un valor entre $[e_{i-1}, e_i)$
- División, ordenamiento y concatenación recursivos de los subarreglos hasta tener todos los elementos ordenados
- El proceso recursivo termina cuando el subarreglo es de *B* elementos (cabe en un bloque de tamaño *B*)

ORDENAMIENTO POR DISTRIBUCIÓN PARA MEMORIA EXTERNA (2)

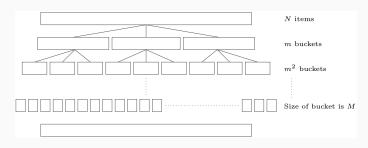
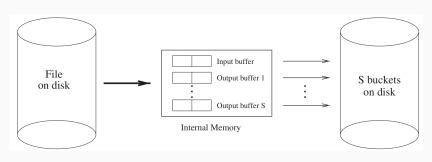


Imagen tomada de Lars Arge: External-Memory Algorithms with Applications in Geographic Information Systems, 1996.

Ordenamiento por distribución para memoria externa (3)

· Retos

- Encontrar elementos que generen subarreglos de tamaño similar
- Cuando *D* > 1, balancear la carga entre los discos
- · Estrategia de escritura de subarreglos en disco



Ordenamiento por mezcla en memoria interna (1)

- Algoritmo de ordenamiento basado comparaciones diseñado por John von Neumann
- · Paradigma divide y vencerás
 - 1. Divide recursivamente el arreglo de *N* elementos hasta obtener *N* subarreglos de un solo elemento
 - 2. Ordenar y mezclar repetidamente los subarreglos ordenados hasta que quede un solo arreglo
- Complejidad O(N log N): log N niveles y N comparaciones en cada nivel

ORDENAMIENTO POR MEZCLA EN MEMORIA INTERNA (2)

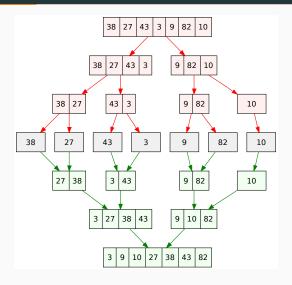


Imagen tomada de Wikipedia (Merge Sort)

ORDENAMIENTO POR MEZCLA EN MEMORIA EXTERNA: DIVISIÓN

- · Divide arreglo en N/M subarreglos de tamaño M
- · Ordena cada subarreglo de forma independiente (trabajo)
- · 2N/B transferencias, 2M/B por subarreglo
- · N log M comparaciones, M log M por subarreglo

Ordenamiento por mezcla en memoria externa: mezcla

- Mezcla 2 trabajos R y S de tamaño L en uno solo T de tamaño 2L (conocido como mezcla de 2 caminos)
 - 1. Carga primeros bloques \hat{R} y \hat{S} de R y S
 - 2. Aloja el primer bloque \hat{T} de T
 - 3. Mientras haya elementos en R y S
 - a. Mezcla todos los posibles elementos de \hat{R} y \hat{S} en \hat{T}
 - b. Si ya no hay elementos en \hat{R} o \hat{S} , carga un nuevo bloque
 - c. Si T̂ se llena, cópialo a T
 - 4. Copia el resto de elementos de R o S a T
- Transferencias: $\frac{2L}{B}$ lecturas, $\frac{2L}{B}$ escrituras y 2L comparaciones

MEZCLA DE K CAMINOS

- Mezcla K trabajos de forma eficiente (por ej. con montículos mínimos)
- $\cdot \frac{2KL}{B}$ transferencias por mezcla
- · Maximiza K para reducir transferencias
 - (K lecturas + 1 escritura) B = M
 - Total de transferencias $O\left(\frac{N}{B}\log_{M/B}\frac{N}{B}\right)$

ORDENAMIENTO POR MEZCLA EN MEMORIA EXTERNA (2)

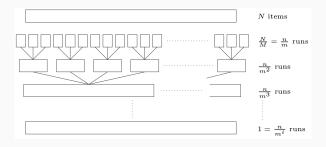


Imagen tomada de Lars Arge: External-Memory Algorithms with Applications in Geographic Information Systems, 1996.

ORDENAMIENTO POR MEZCLA EN MEMORIA EXTERNA (3)

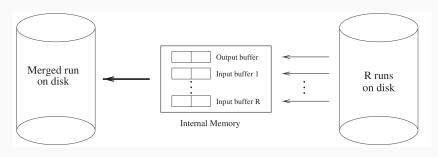


Imagen tomada de Vitter: Algorithms and Data Structures for External Memory, 2008.

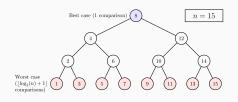
Ordenamiento en modelo de inconsciente de caché

- Es posible usar el ordenamiento por mezcla de 2 caminos pero no es muy eficiente
- · Alternativa más eficiente: ordenamiento de embudo
 - 1. Divide el arreglo en $K = N^{1/3}$ subarreglos contiguos (cada uno de tamaño $N/K = N^{2/3}$) y los ordena de forma recursiva
 - 2. Mezcla los *K* subarreglos ordenados de forma eficiente usando *K*-embudos¹
- Ordenamiento de embudo requiere $O(\frac{N}{B} \log_{M/B} \frac{N}{B})$ transferencias

¹Demaine: Cache-Oblivious Algorithms and Data Structures, 2002

BÚSQUEDA DE ELEMENTOS

- Dado un arreglo de N elementos, determinar si un elemento de consulta q está en el arreglo
- Recorriendo todos los elementos tomaría O(N/B) operaciones E/S
- Si están ordenados podríamos usar búsqueda binaria y tomaría $O\left(\log_2 \frac{N}{B}\right)$ operaciones E/S



ALGORITMOS DE BÚSQUEDA PARA MEMORIA EXTERNA

- Hashing
 - · Métodos con directorios
 - · Métodos sin directorios
- · Algoritmos de árboles
 - Árboles-B y variantes
 - · Árboles de buffer

HASHING EXTENDIBLE

- · Directorio
 - Consiste de una tabla con 2^d referencias, donde $d \ge 0$
 - La ubicación en la tabla de un elemento está dada por los d bits menos significativos de su valor hash

$$hash_d(x) = hash(x) \mod 2^d$$

- Cada ubicación de la tabla contiene una referencia a un bloque donde se almacenan los elementos
- Una ubicación comparte el mismo bloque con las ubicaciones con los mismos k bits menos significativos

$$hash_k(x) = hash_d(x) \mod 2^k$$

- Búsquedas requieren 2 operaciones E/S si el directorio reside en disco
 - · Acceso a ubicación de la tabla
 - · Acceso a bloque asignado a ubicación

PROFUNDIDAD GLOBAL Y LOCAL

- · d es la profundidad global
 - Se elige el número más pequeño con el cual cada ubicación de la tabla tiene a lo mucho B elementos
- · k es la profundidad local
 - Se elige el número más pequeño para que los elementos asignados entren en un solo bloque
- · Cuando un bloque se desborda, d y k se recalculan
 - Se divide el bloque y se redistribuyen sus elementos
 - El tamaño del directorio crece (se duplica cuando d se incremente en 1)
 - Permite adaptarse al crecimiento en el número de elementos N

HASHING LINEAR

- No necesita directorio: cada ubicación de la tabla corresponde a un bloque donde se almacenan elementos
- Cuando hay desbordamiento, un bloque predefinido de la tabla se divide y sus elementos se redistribuyen
 - El bloque que se divide no es necesariamente el que se desbordó, por lo que los bloques desbordados necesitan listas auxiliares para almacenar elementos desbordados
- · Búsquedas requieren usualmente una sola operación E/S

ÁRBOLES-B

- Árboles balanceados que mantienen sus elementos ordenados
 - Operaciones: escaneo secuencial, inserción, eliminación y búsqueda
- Definición de árbol-B de orden m²
 - · Cada nodo tiene a lo mucho *m* hijos
 - Cada nodo no hoja tiene al menos $\lceil m/2 \rceil$ hijos (excepto la raíz)
 - · Si no es hoja, el nodo raíz tiene al menos 2 hijos
 - Un nodo no hoja con k hijos contiene k 1 valores de separación (llaves)
 - · Los nodos hoja están en el mismo nivel del árbol
 - · Elementos de un nodo están ordenados

²De acuerdo a D. Knuth: Sorting and Searching, The Art of Computer Programming, vol. 3.

EJEMPLO DE ÁRBOL-B

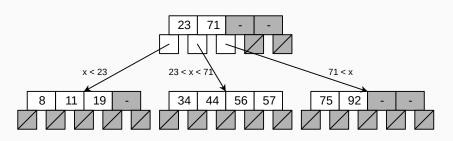


Imagen tomada de Wikipedia (Árbol-B)

Inserción en árboles-B

- · Se hacen de nodos hoja a raíz
 - Se encuentra el nodo hoja donde insertar el elemento
 - Si el nodo hoja tiene menos elementos que el máximo, se inserta en ese nodo
 - 3. En caso contrario, se divide en 2
 - a) Escoge mediana de elementos del nodo y nuevo elemento
 - b) Valores menores a mediana se agregan en hijo izquierdo y mayores en hijo derecho
 - c) La mediana se inserta en nodo padre, si excede capacidad se divide en 2 (se repite a)-c))
 - d) Si se llega a raíz, se crea nueva

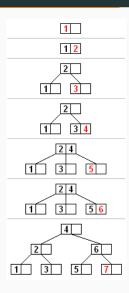


Imagen tomada de Wikipedia (B-tree)

Eliminación en árboles-B

- · Eliminación en un nodo hoja
 - 1. Se busca el elemento a eliminar
 - 2. Si el valor se encuentra en un nodo hoja, se elimina
 - 3. Si queda con muy pocos elementos, se rebalancea
- · Eliminación en un nodo no hoja (interno)
 - 1. Encuentra un nuevo separador que substituya al elemento
 - Toma elemento más grande del hijo izquierdo o el más pequeño del derecho, elimínalo del sub-árbol correspondiente y reemplaza con este el elemento a eliminar
 - 3. Rebalancea sub-árbol, si es necesario

Búsqueda en árboles-B

- 1. Se recorre el árbol de la raíz a las hojas
- Si el elemento está almacenado en el nodo la búsqueda termina y si no se continúa con el sub-árbol correspondiente al valor a buscar
- 3. Si estamos en un nodo hoja y el elemento no está almacenado, entonces no se encontró